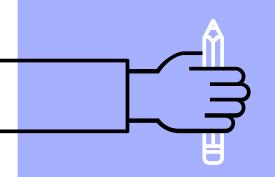


Proyecto 1

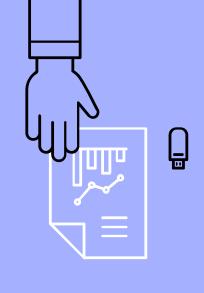
Kevin Babativa Nicolás Angarita Nicolás Alvarado



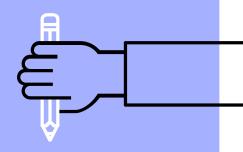


Metodología









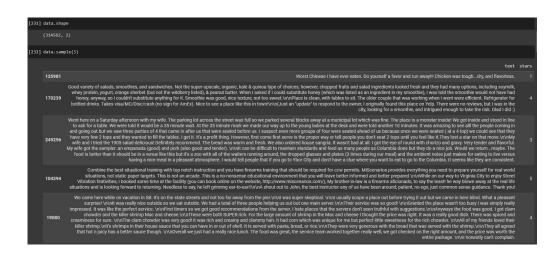
Entendimiento y preprocesamiento

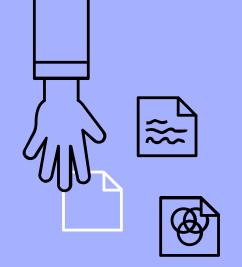


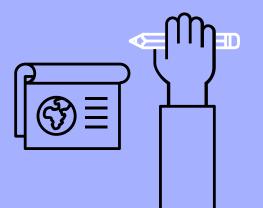
Entendimiento

Se tienen 314562 datos en el archivo.

Cada fila consiste en un texto y una calificación de 1 a 5.



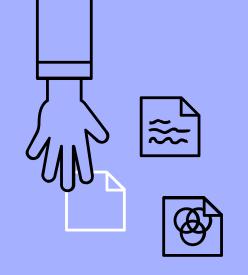




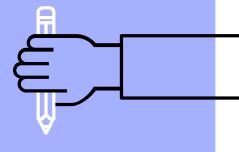
Preprocesamiento

Se divide el dataset en entrenamiento y testeo, se toma el 80% del dataset (251649) como **entrenamiento**.

[234] X_train, X_test, y_train, y_test = train_test_split(data['text'], data['stars'], test_size = 0.2, stratify = data['stars'], random_state = 1)







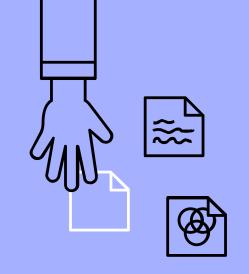
Tokenización



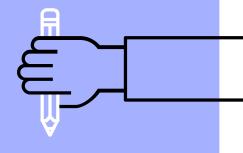
Tokenización

La tarea de tokenización se apoya en la librería NLKT para diversas funciones. De igual manera, se eliminan caracteres especiales y se hace un proceso de *lemmatizing* y *stemming* con el fin de solo conservar la base de las palabras. Todo lo anterior partiendo únicamente del idioma inglés.

```
lemmatizer = WordNetLemmatizer()
ps = PorterStemmer()
def tokenizer(text):
    text = text.replace("\n", " ")
    tokens = word_tokenize(text)
    tokens = [t for t in tokens if t.isalpha()]
    tokens = [lemmatizer.lemmatize(t) for t in tokens]
    tokens = [ps.stem(t) for t in tokens]
    tokens = [t for t in tokens if len(t) > 2]
    return tokens
```





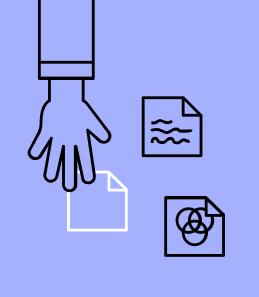


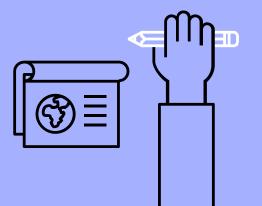
Modelos



Generalidades

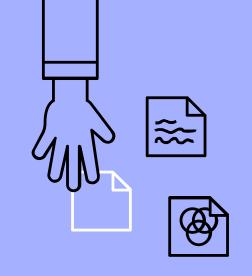
Para cada modelo se crearon dos <u>Pipelines</u>, uno cuya primera tarea era realizar la función <u>CountVectorizer</u>, que nos ayuda a vectorizar los tokens calculados. Como segunda tarea el pipeline realiza el modelo escogido. Y el segundo Pipeline hace lo mismo pero con <u>TfidfVectorizer</u>.

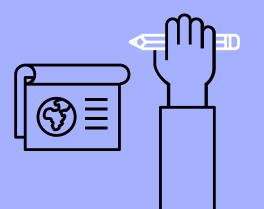




Naive Bayes

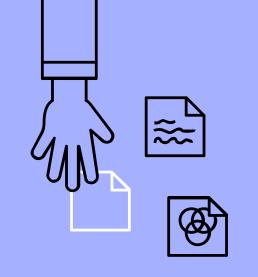
Fue escogido por su rapidez dentro de los algoritmos que necesitan de transformación. La transformación se hizo con la estrategia OneVsRest y después se aplicó el modelo de Bayes.





Decision Tree

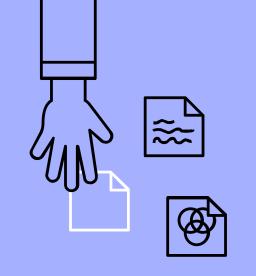
Fue escogido por su simplicidad y los insights que fácilmente se pueden determinar a partir de los resultados.



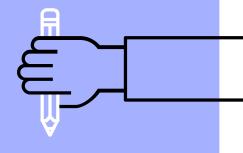


Random Forest

Fue escogido por ser la sucesión de Decision Tree, ambos algoritmos en conjunto aportan grandes insights para el proyecto.





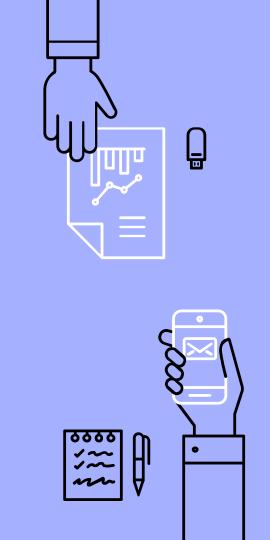


Resultados



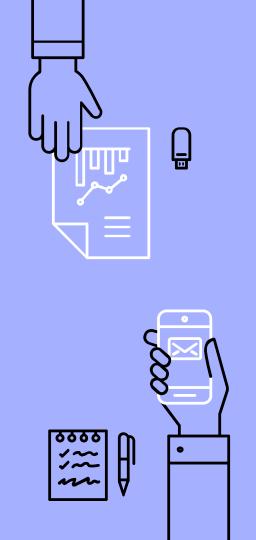
Comparación (CountVectorizer)

	Naive Bayes	Decision Tree	Random Forest
Micro F1 Score	0.63	0.52	0.60
Macro F1 Score	0.50	0.40	0.36
Hamming Loss	0.37	0.48	0.40
F1 Score weighted	0.62	0.51	0.51



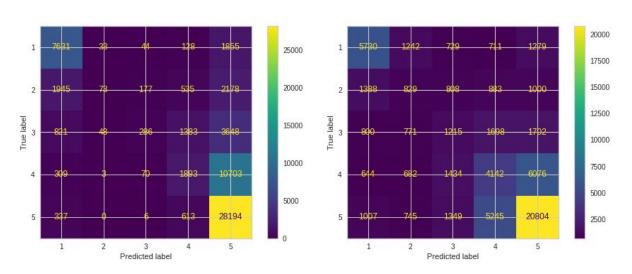
Comparación (TfidfVectorizer)

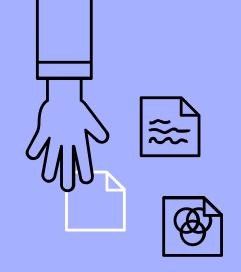
	Naive Bayes	Decision Tree	Random Forest
Micro F1 Score	0.58	0.51	0.60
Macro F1 Score	0.31	0.39	0.35
Hamming Loss	0.42	0.49	0.40
F1Score weighted	0.47	0.51	0.51



Resultados

RandomForest y DecisionTree

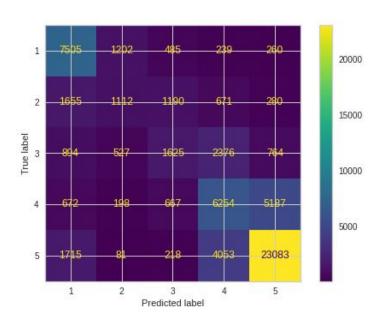




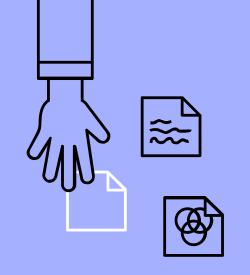


Resultados

Naive Bayes

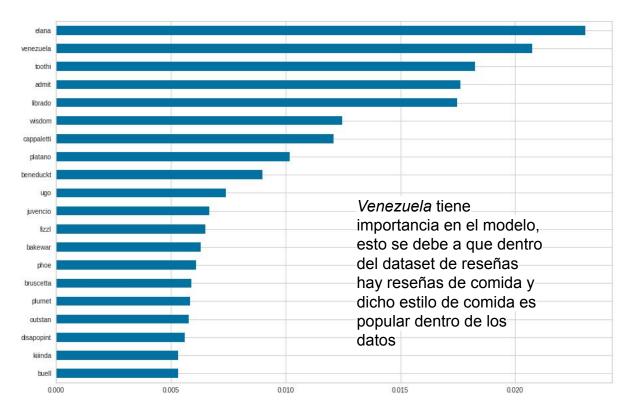


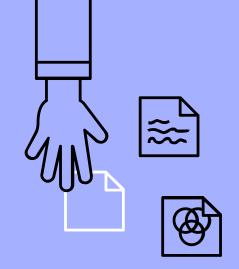
No es lo ideal pero se puede usar para clasificar comentarios entre buenos y malos.





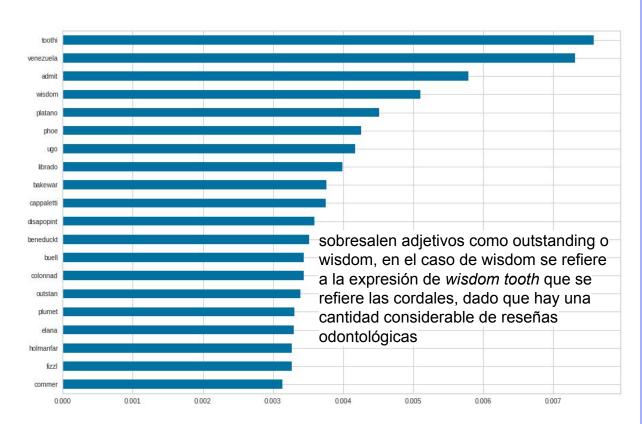
Graficas

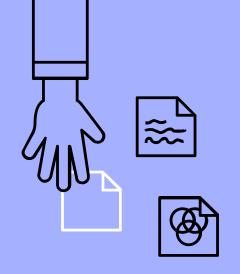




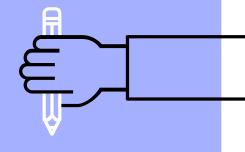


Graficas









Conclusiones



Recomendaciones

El algoritmo de Naive Bayes logró la meta propuesta, pero por muy poco por lo que se podría intentar mejorar haciendo cambios en el proceso de entrenamiento. Para los otros dos algoritmos, no están lo suficientemente cerca de la meta por lo que no deben ser tomados en cuenta, más allá de como una fuente de información pero no de toma de decisión.

Se le sugiere a cualquier empresa que quiera usar este modelo que lo use de esa forma, para definir comentarios buenos y malos teniendo en cuenta los comentarios que tienen 1,4 y 5 estrellas. Estos resultados se dieron por la cantidad desproporcionada de comentarios con 5 y 1 estrellas.

